



دانشکده مهندسی کامپیوتر

## تمرین سری ۱۴ بینایی کامپیوتر

**نام درس**

مبانی بینایی کامپیوتر

**نام دانشجو**

زهرا انوریان

**نام استاد درس**

دکتر محمدی

زمستان ۱۳۹۹

۱. ✍

الف) علت به وجود آمدن مشکل underfitting در شبکه چیست و چه زمانی رخ می‌دهد؟ (۵ نمره)  
**پاسخ:** زمانی این اتفاق رخ می‌دهد که مدل ما به دلیل اینکه داده‌ی زیادی یاد نگرفته است، نمی‌تواند به درستی پیش‌بینی کند و دقت خوبی ندارد و دارای خطاست.

ب) مشکل بیش‌برازش (overfitting) چیست؟ چه راه‌هایی برای رفع آن پیشنهاد می‌کنید؟ (۵ نمره)  
**پاسخ:** زمانی این اتفاق رخ می‌دهد که مدل ما داده‌های آموزش را حفظ کرده باشد یعنی دقت آن بر روی داده‌های آموزش زیاد و بر روی داده‌های تست کم باشد و به خوبی پیش‌بینی نکند و برای حل این مشکل می‌توان مسئله را برایش سخت‌تر کرد. برای این کار می‌توان از dropout (حذف برخی از نورون‌ها از شبکه با یک rate به صورت تصادفی) استفاده کرد (در واقع به شبکه نویز اضافه می‌کنیم) و همچنین می‌توان با استفاده از الگوریتم‌های داده‌افزایی از حفظ کردن داده‌های ورودی توسط مدل جلوگیری کنیم.

۲. ✍ استفاده از شبکه‌های pre-train یکی از روش‌های موثر برای مقداردهی اولیه پارامترهای یک شبکه است. در مورد نحوه استفاده از این نوع یادگیری و مزایای آن، توضیح دهید. (۱۰ نمره)

**پاسخ:** اگر دیتاست ما کوچک بود می‌توان از شبکه‌های pre-train استفاده کرد به این صورت که کل شبکه به صورت فریز قرار گیرد و فقط لایه‌ی آخر آن که دسته‌بندی داده‌ها را برعهده دارد برحسب دسته‌های مسئله‌ی خود آموزش داد اما اگر دیتاست ما بزرگ بود می‌توان تنها لایه‌های کانولوشن را فریز گذاشت و لایه‌های مربوط به استخراج ویژگی را با دیتاست خود آموزش داد تا ویژگی‌های بدست آمده دقیق‌تر باشد و یا حتی می‌توان به جای مقداردهی اولیه‌ی پارامترهای شبکه از پارامترهای شبکه‌ی آموزش دیده استفاده کرد و اگر دیتاست متفاوت از شبکه‌ی آموزش دیده بود می‌توان در هر لایه‌ای از ابتدای شبکه دسته‌بند را اعمال کرد و تنها ویژگی‌های عام را توسط شبکه‌ی آموزش دیده بدست آورد. مزیت استفاده از شبکه‌های آموزش دیده، افزایش سرعت در آموزش، بالا بردن دقت شبکه و حتی آسان‌تر شدن کار می‌باشد.

۳. ✍ اگر یک تصویر ۳ کاناله با ابعاد ۲۸ در ۲۸ داشته باشیم، تعداد پارامترها را برای یک لایه کانولوشنی با تعداد ۱۲۸ فیلتر ۵×۵ را در حالتی که از کانولوشن ساده و کانولوشن با عمق جداپذیر (Depthwise Separable Convolution) استفاده می‌شود (به ازای depth\_multiplier برابر با ۲)، به دست آورده و با هم مقایسه کنید. (۱۰ نمره)  
**پاسخ:**

$$Parameters: F.F.K.D_1 + k(bias) =$$

$$(5 * 5 * 128 * 3) + 128 = 9728$$

$$Parameters: 2 * (5 * 5 + 1) + 128$$

$$* (3 * 2 + 1)$$

$$= 306 + 17152 = 948$$

۴. (۷۰ نمره) در این سوال میخواهیم یک مسئله دسته‌بندی را با استفاده از تکنیک‌های داده‌افزایی و انتقال یادگیری انجام دهیم.

در این سوال از مجموعه‌داده [cars](#) استفاده می‌کنیم که شامل ۱۶۱۸۵ تصویر است و ۱۹۶ کلاس دارد. تعداد تصاویر آموزشی در این مجموعه‌داده برابر با ۸۱۴۴ و تعداد تصاویر آزمون برابر با ۸۰۴۱ است. برای دانلود این مجموعه‌داده کافی است مراحل که در فایل HW14.ipynb ذکر شده است انجام دهید تا مجموعه‌داده در Google Drive شما ذخیره گردد. پس از انجام این مراحل پوشه‌هایی به نام stanford\_car\_dataset در درایو شما ایجاد شده است که محتویات آن باید مطابق شکل زیر باشد:



داخل هر کدام از پوشه‌های train و test، ۱۹۶ پوشه دیگر وجود دارد که داخل هر کدام از آن‌ها تصاویر مربوط به یکی از ۱۹۶ کلاس است و نام این پوشه‌ها نشان‌دهنده‌ی آن کلاس است. برای مثال در پوشه 2012BMW 1 Series Convertible تصاویر مربوط به کلاس 2012BMW 1 Series Convertible وجود دارد. در ادامه توضیح خواهیم داد که چگونه این ساختار ذخیره‌سازی به ما کمک خواهد کرد تا مجموعه‌داده را به مدل یادگیری عمیق ورودی بدهیم.

معمولاً برای آموزش مدل‌های یادگیری عمیق، از مجموعه‌داده‌های نسبتاً بزرگی استفاده می‌شود که حتی پیشرفته‌ترین سخت‌افزارها، حافظه کافی برای پردازش داده‌ها به صورت یکجا و یکپارچه را ندارند. به همین دلیل است که ما باید راه‌های دیگری برای انجام کارآمد آن پیدا کنیم. در ادامه قصد داریم به شما نشان دهیم که چگونه مجموعه‌داده را در چندین هسته و در زمان اجرا تولید کرده و بلافاصله آن را به مدل یادگیری عمیق خود بدهیم. بدین منظور کلاسی به نام [ImageDataGenerator](#) در keras پیاده‌سازی شده است که همزمان با تولید batchی از تصاویر در زمان اجرا، می‌تواند اعمال مختلف داده‌افزایی مانند rotation، flipping و ... را انجام دهد. باتوجه به ساختار ذخیره‌سازی مجموعه‌داده cars

که قبلاً ذکر شد؛ در این مسئله می‌توانیم به راحتی از تابع `flow_from_directory` برای تولید تصاویر استفاده کنیم. در غیر این صورت باید خودمان با توجه به نیاز مسئله کلاس `generator` را پیاده‌سازی می‌کردیم (اگر علاقه‌مند به نوشتن `custom generator` هستید؛ از این [لینک](#) استفاده نمائید). برای آشنایی بیشتر با `ImageDataGenerator` و نحوه استفاده از آن برای داده‌افزایی، از مثال موجود در [لینک](#) استفاده نمائید.

الف) در این قسمت شما باید برای هر کدام از داده‌های آموزشی و داده‌های تست، به ترتیب دو `generator` با استفاده از `ImageDataGenerator` و `flow_from_directory` با نام‌های `train_datagen` و `test_datagen` بسازید. سپس از `resnet50` (موجود در کراس) با **وزنه‌ای تصادفی** استفاده کنید و یک مدل برای این مسئله طراحی کنید. پس از آموزش مدل، آن را بر روی داده‌های تست ارزیابی کنید.

**پاسخ:** با استفاده از `batch_size=80` و `epoch=25` توانستم به دقت ۹۵ درصد بر روی داده‌های آموزش و به دقت ۱۹ درصد بر روی داده‌های تست برسیم (البته با `epoch`های بیشتر بر روی داده‌های تست می‌توان به درصد بهتری نیز رسید) که این نشان‌دهنده‌ی `overfitting` مدل می‌باشد که در واقع داده‌های آموزش را حفظ کرده و دقتش در آن بالاست ولی در داده‌ی تست که جدید است و تا به حال آن را ندیده ضعیف عمل می‌کند. حال برای رفع این مسئله می‌توان از `dropout` و یا داده‌افزایی استفاده کرد که در بخش بعد داده‌افزایی را بررسی می‌کنیم.

Model: "sequential"

Layer (type)	Output Shape	Param #
resnet50 (Functional)	(None, 2048)	23587712
dense (Dense)	(None, 196)	401604
Total params: 23,989,316		
Trainable params: 23,936,196		
Non-trainable params: 53,120		

```
Epoch 24/25
102/102 [=====] - 102s 993ms/step - loss: 0.2119 - accuracy: 0.9438
Epoch 25/25
102/102 [=====] - 105s 1s/step - loss: 0.1722 - accuracy: 0.9535
<tensorflow.python.keras.callbacks.History at 0x7f2b08f9dda0>
```

```
model.evaluate(test_generator, batch_size=BATCH_SIZE)
```

```
101/101 [=====] - 85s 833ms/step - loss: 5.6033 - accuracy: 0.1897
[5.603324890136719, 0.18965302407741547]
```

ب) در این قسمت، از مدلی که در قسمت الف طراحی کرده‌اید؛ استفاده کنید و این بار مدل را با داده‌افزایی آموزش دهید. بنابراین برای داده‌های آموزشی یک `generator` با استفاده از `ImageDataGenerator` و `flow_from_directory` با نام `train_datagen_aug` بسازید که برای داده‌های آموزشی نیز داده‌افزایی

انجام دهد. پس از آموزش مدل، آن را بر روی داده‌های تست ارزیابی کنید. نتیجه حاصل از این قسمت را با قسمت الف مقایسه نمایید.

**پاسخ:** در این قسمت با استفاده از تابع `ImageDataGenerator` و به کمک پارامترهای آن در داده‌های آموزش تغییر ایجاد می‌کنیم و از حفظ کردن داده‌ها توسط مدل جلوگیری می‌کنیم. با تعیین `epoch=50` و `batch_size=80` به ۸۸ درصد بر روی داده‌های آموزش و بر روی داده‌های تست به ۴۲ درصد رسیدم.

```
Epoch 49/50
102/102 [=====] - 168s 2s/step - loss: 0.4272 - accuracy: 0.8740
Epoch 50/50
102/102 [=====] - 171s 2s/step - loss: 0.3903 - accuracy: 0.8850
<tensorflow.python.keras.callbacks.History at 0x7f1250b4d240>
```

```
model.evaluate(test_generator, batch_size=BATCH_SIZE)
```

```
101/101 [=====] - 1793s 18s/step - loss: 3.3639 - accuracy: 0.4257
[3.3639113903045654, 0.4256933331489563]
```

پ) در این قسمت از شبکه از قبل آموزش دیده `ResNet50` بر روی مجموعه داده `Imagenet` استفاده کنید ([لینک](#)) و پس از آن یک دسته‌بند قرار دهید. موقع آموزش یک بار تمامی وزن‌های شبکه `ResNet50` را `freeze` کنید و مابقی وزن‌ها را آموزش دهید. در بار دیگر بگذارید تا وزن‌های شبکه `ResNet50` نیز آموزش ببینند (`fine tuning`). برای آموزش این مدل در هر دو حالت از `generator` `train_datagen_aug` با داده‌افزایی استفاده نمایید. پس از آموزش مدل، آن را بر روی داده‌های تست ارزیابی کنید. نتیجه حاصل از این قسمت را با قسمت الف و ب مقایسه نمایید.

پاسخ: ابتدا وزن‌های شبکه‌ی `imagenet` را برای شبکه‌ی `resnet50` در نظر می‌گیریم و کل شبکه را فریز می‌کنیم و یک لایه‌ی `dense` که دارای ۱۰۲۴ نورون است را به شبکه‌ی `resnet50` اضافه می‌کنیم. حال با `epoch=50` و `batch_size=80` به ۴۵ درصد دقت بر روی داده‌های تست می‌رسیم.

```
Epoch 47/50
102/102 [=====] - 222s 2s/step - loss: 0.4317 - accuracy: 0.8719 - val_loss: 2.8020 - val_accuracy: 0.4512
Epoch 48/50
102/102 [=====] - 221s 2s/step - loss: 0.4115 - accuracy: 0.8756 - val_loss: 2.9014 - val_accuracy: 0.4333
Epoch 49/50
102/102 [=====] - 222s 2s/step - loss: 0.4329 - accuracy: 0.8730 - val_loss: 2.8095 - val_accuracy: 0.4476
Epoch 50/50
102/102 [=====] - 222s 2s/step - loss: 0.4073 - accuracy: 0.8803 - val_loss: 2.8265 - val_accuracy: 0.4419
```

و برای `fine tuning` نیز ۳۰ لایه‌ی آخر شبکه‌ی `resnet50` با وزن‌های `imagenet` را `trainable` در نظر می‌گیریم و بقیه را فریز می‌کنیم و از الگوریتم `SGD` (با `momentum`) برای بهینه‌سازی استفاده می‌کنیم. با `epoch=35` و `batch_size=80` به ۷۵ درصد دقت بر روی داده‌های تست می‌رسیم.

```

Epoch 25/35
102/102 [=====] - 232s 2s/step - loss: 0.0532 - accuracy: 0.9851 - val_loss: 1.3232 - val_accuracy: 0.7071
Epoch 26/35
102/102 [=====] - 233s 2s/step - loss: 0.0413 - accuracy: 0.9891 - val_loss: 1.1602 - val_accuracy: 0.7514
Epoch 27/35
102/102 [=====] - 233s 2s/step - loss: 0.0419 - accuracy: 0.9867 - val_loss: 1.3729 - val_accuracy: 0.7141
Epoch 28/35
102/102 [=====] - 232s 2s/step - loss: 0.0447 - accuracy: 0.9867 - val_loss: 1.2395 - val_accuracy: 0.7301
Epoch 29/35
102/102 [=====] - 233s 2s/step - loss: 0.0332 - accuracy: 0.9913 - val_loss: 1.2434 - val_accuracy: 0.7385
Epoch 30/35
102/102 [=====] - 233s 2s/step - loss: 0.0372 - accuracy: 0.9887 - val_loss: 1.6215 - val_accuracy: 0.6757
Epoch 31/35
102/102 [=====] - 233s 2s/step - loss: 0.0410 - accuracy: 0.9877 - val_loss: 1.5911 - val_accuracy: 0.6847
Epoch 32/35
102/102 [=====] - 232s 2s/step - loss: 0.0382 - accuracy: 0.9896 - val_loss: 1.1970 - val_accuracy: 0.7405
Epoch 33/35
102/102 [=====] - 232s 2s/step - loss: 0.0374 - accuracy: 0.9888 - val_loss: 1.2060 - val_accuracy: 0.7417
Epoch 34/35
102/102 [=====] - 234s 2s/step - loss: 0.0347 - accuracy: 0.9905 - val_loss: 1.2535 - val_accuracy: 0.7500
Epoch 35/35
102/102 [=====] - 233s 2s/step - loss: 0.0328 - accuracy: 0.9907 - val_loss: 1.3100 - val_accuracy: 0.7268

```

چند نکته برای طراحی مدل یادگیری عمیق:

- برای آموزش مدل از تابع [fit](#) استفاده نمائید و برخلاف قبل، به جای ورودی دادن داده‌های آموزشی و برچسب آن، کافی است generator داده‌های آموزشی را به تابع fit ورودی بدهید. نیازی به استفاده از fit\_generator در نسخه جدید تانسورفلو نیست.
- برای ارزیابی مدل نیز کافی است از تابع [evaluate](#) استفاده نمائید و generator داده‌های تست را به آن ورودی دهید.
- موفق باشید.